

Radar de Provedores

Ferramenta de IA para prospecção e qualificação de ISPs regionais

Disciplina de Tecnologia | João — Grupo Sun Investimentos | Documento conceitual (nome-rascunho)

Resumo

A ferramenta encontra, estrutura e **qualifica automaticamente** pequenos e médios provedores de internet (ISPs) do interior de São Paulo, gerando uma lista priorizada das operadoras com maior aderência ao perfil de cliente de uma boutique de assessoria em telecom. Ela **não raspa a internet inteira**: combina poucas fontes oficiais e públicas de alta qualidade (Anatel e Receita Federal) com uma camada de IA que enriquece, cruza e pontua cada operadora. O valor está na **inteligência de qualificação** — decidir, com justificativa, quais provedores valem uma abordagem e por quê.

1. Contexto

A boutique atende uma lacuna de mercado: provedores regionais operam sem acesso a serviços profissionais de contabilidade, tributário, jurídico e marketing, e têm receio de vender por desconhecerem M&A; e gestão patrimonial. Para esse negócio, saber **quais provedores existem, onde estão, que tamanho têm e quais estão maduros para uma conversa** é a matéria-prima. Hoje isso é manual e artesanal; a ferramenta automatiza e qualifica esse trabalho.

2. Problema que resolve

- **Fragmentação** — quem é provedor, de que porte e onde atua está espalhado em bases que não conversam.
- **Volume** — são centenas de candidatas no interior de SP; revisar na mão é inviável.
- **Qualificação subjetiva** — sem critério padronizado, a decisão de abordar fica no feeling.
- **Timing** — o dado mais valioso (este dono tende a vender agora) não está pronto em nenhuma base; precisa ser inferido.

3. Onde está a Inteligência Artificial

Esta seção separa o projeto de “um banco de dados com filtros”. A IA atua em quatro pontos onde regra fixa não resolve:

- **Extração com LLM** — lê sites, notícias e redes (texto livre) e extrai atributos estruturados: cobertura, tecnologia, porte, donos, tempo de mercado, tom do marketing. [\[Certeza\]](#)
- **Resolução de entidades** — casa a mesma operadora entre Anatel, CNPJ e site (nomes diferentes, sem chave comum) via similaridade. [\[Provável\]](#)
- **Motor de qualificação (scoring)** — **abordagem híbrida**: parte determinística para o objetivo (porte, região, CNAE) + **LLM-como-juiz** com rubrica para o subjetivo (maturidade digital, propensão à venda). Toda nota vem com justificativa. [\[Provável\]](#)
- **Deteção de sinais** — NLP varre notícias buscando gatilhos (expansão, pressão competitiva, troca de sócios, consolidação regional) que alimentam o critério de timing. [\[Provável\]](#)

Honestidade técnica: a coleta e o cruzamento são, em boa parte, engenharia de dados. A IA genuína está na extração, no scoring e na deteção de sinais — assumir isso é sinal de maturidade.

4. Fontes de dados — camadas priorizadas e legais

Em vez de “todos os sistemas da internet”, trabalha-se com camadas, da fonte mais confiável para a menos:

- **Anatel (Dados Abertos)** — acessos de banda larga fixa (SCM) **por prestadora e por município**. Dá porte e área de atuação de cada provedor: o dado central da qualificação. [\[Certeza\]](#)
- **Receita Federal (base pública de CNPJ)** — razão social, situação, data de abertura, capital social, CNAE e quadro de sócios (QSA). Acessível via APIs (BrasilAPI, CNPJá, CNPJ.ws). Filtrando por CNAE de telecom, isola-se o setor. [\[Certeza\]](#)

- **Web pública** (site, redes, notícias) — para enriquecimento, respeitando robots.txt e termos de uso.

A ferramenta NÃO raspa dados atrás de login, não usa lista vazada e não coleta dado pessoal privado do sócio — usa o dado comercial e público. Isso é o que protege o projeto juridicamente.

5. Perfil de Cliente Ideal (ICP) e qualificação

Critério	Sinal de bom encaixe	Confiança
Serviço	Provedor SCM (banda larga fixa) independente/regional	Certeza
Região	Município do interior de SP (excluir capital e RMSP)	Certeza
Porte	Faixa “doce”: ~3.000 a 30.000 acessos	Chute — calibrar
Societário	Poucos sócios, empresa familiar	Provável
Tempo de mercado	Muitos anos (indício de fundador maduro, mais aberto a sair)	Provável
Maturidade digital	Site/marketing fraco = fit com a tese da boutique	Provável
Timing	Consolidação regional, pressão competitiva, indícios de saída	Chute — inferência

Os critérios objetivos (porte, região) entram com peso fixo; os moles passam pelo LLM-como-juiz. A soma ponderada gera a nota 0–100 com justificativa. **A faixa de porte e os pesos são hipóteses a calibrar** contra uma amostra de operadoras conhecidas — não verdades prontas.

6. Pipeline

- **1. Coleta** — puxa Anatel (acessos/município) + CNPJ filtrado por CNAE no recorte geográfico.
- **2. Enriquecimento (IA)** — o LLM lê site/redes/notícias e completa os atributos que faltam.
- **3. Cruzamento (IA)** — unifica registros da mesma empresa em um dossiê único.
- **4. Qualificação (IA)** — aplica a rubrica do ICP, calcula a nota com justificativa e ordena a fila para o CRM.

7. LGPD (governança)

- Dado de **pessoa jurídica** (CNPJ, razão social, CNAE, capital) não é dado pessoal e pode ser usado livremente.
- Dado do **sócio** é dado pessoal, ainda que público: base legal do **legítimo interesse (Art. 7º, IX)**, com minimização, transparência e respeito ao opt-out.
- Limites: nada de scraping atrás de login, lista vazada, dado sensível ou contato pessoal privado. A abordagem é comercial, ligada à atividade da empresa-alvo.

8. Escopo do MVP e limitações

MVP demonstrável: ingestão de Anatel + CNPJ para uma região do interior de SP; enriquecimento via LLM a partir do site; motor de qualificação híbrido com rubrica; saída em painel/planilha ranqueada com nota e justificativa.

Limitações a assumir (assumir fraqueza é mais forte que escondê-la): dados da Anatel são declarados e têm defasagem mensal; os pesos do ICP são hipóteses; “propensão à venda” é inferência indireta; APIs gratuitas de CNPJ têm limite de requisição.

Fontes: Anatel — Painéis e Dados Abertos de Acessos (SCM); Receita Federal — base pública de CNPJ (via BrasilAPI/CNPJ/CNPJ.ws); LGPD Art. 7º, IX e Guia de Legítimo Interesse da ANPD.